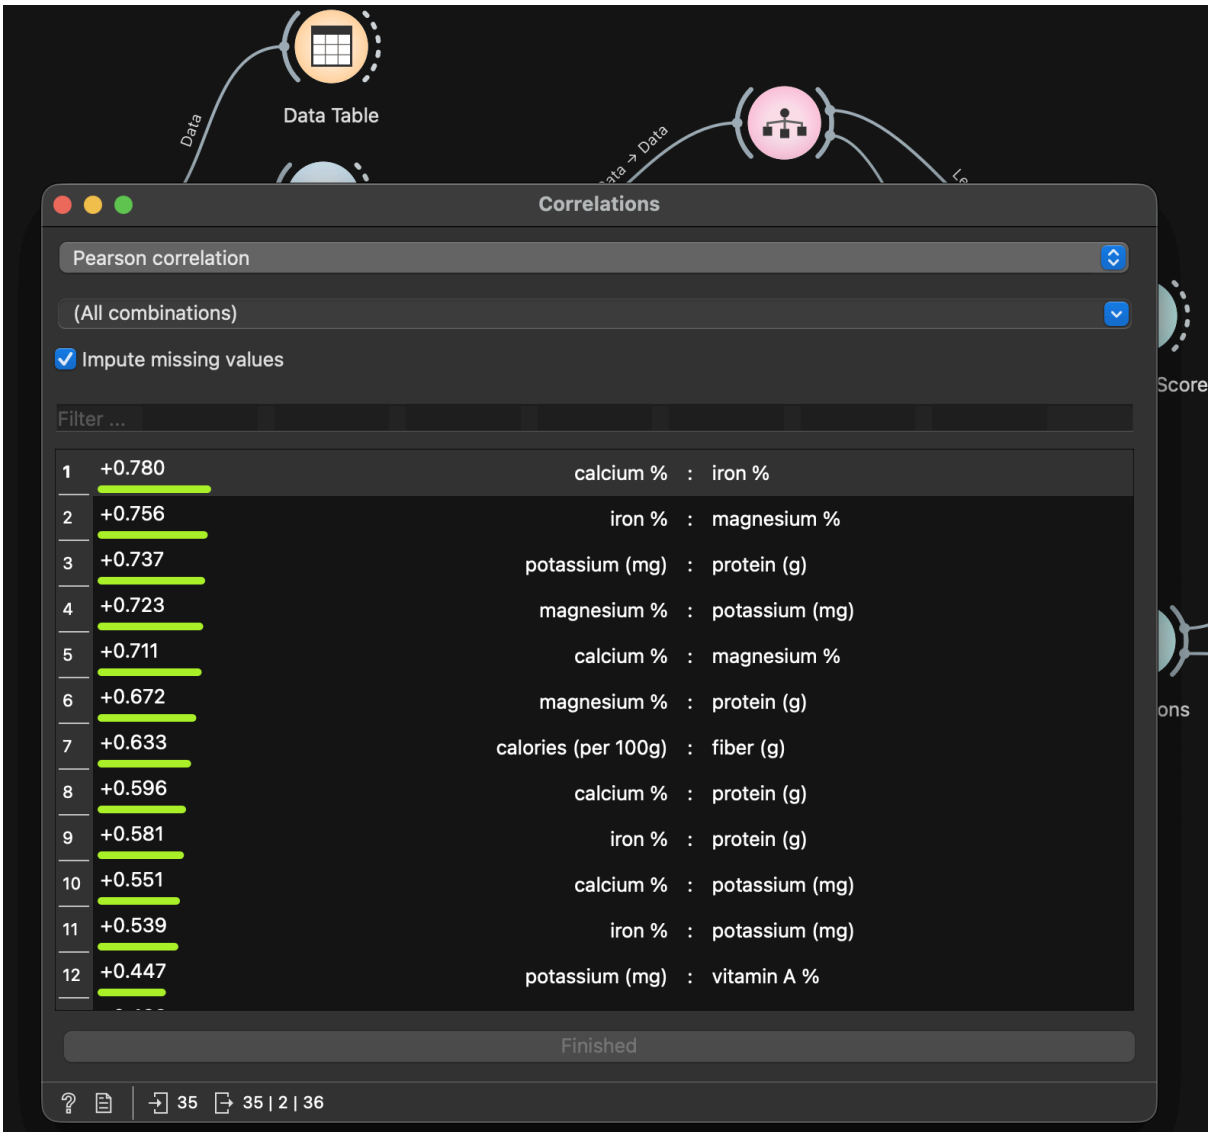
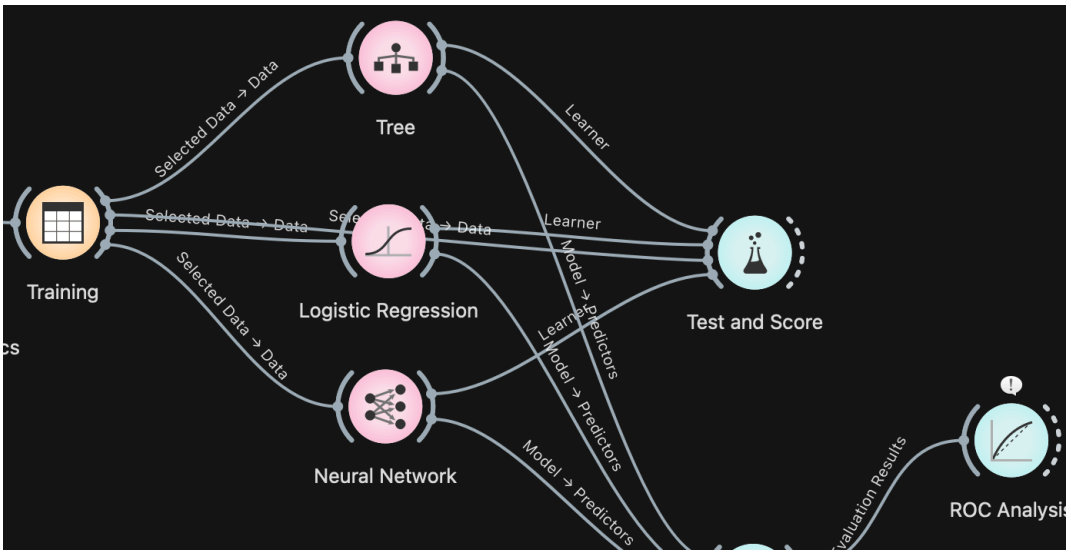
Análisis exploratorio de los datos

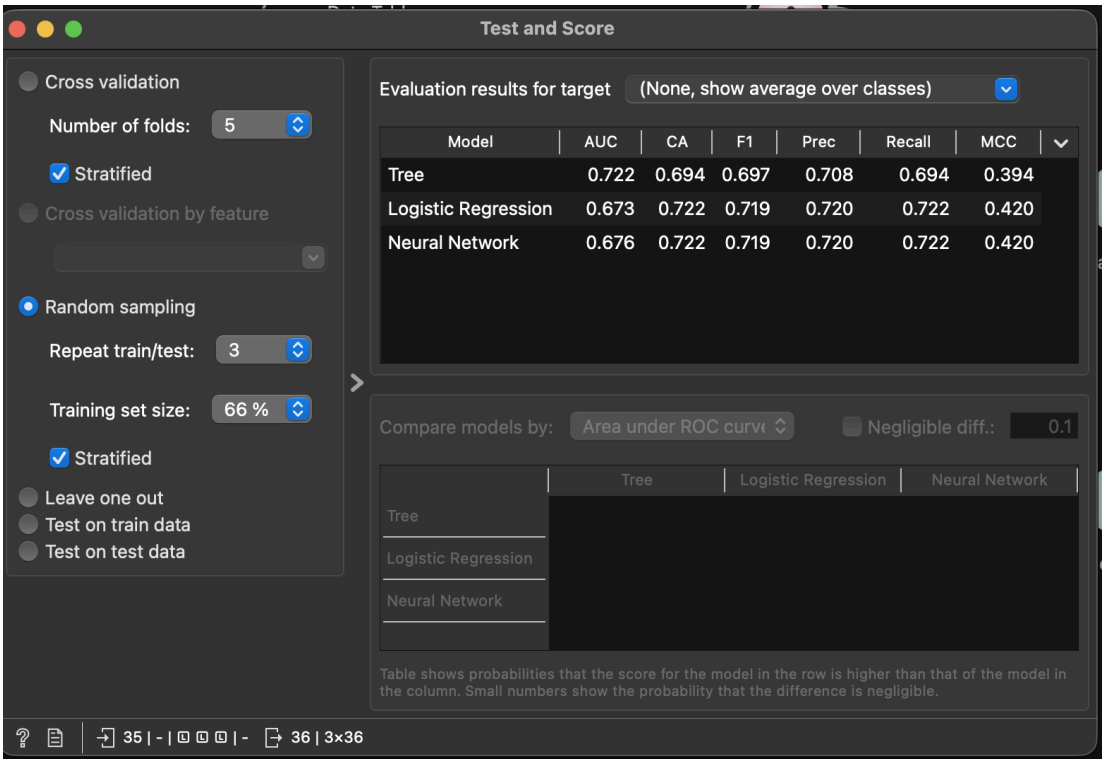
Durante la exploración de los nutrientes usando la herramienta *Correlations*, notamos que los alimentos con mucho calcio suelen tener también altos niveles de hierro, arrojando la correlación de Pearson más fuerte con un valor de 0,780, aunque vale aclarar que esto es solo una asociación y no significa que un aumento cause el otro. También encontramos otras relaciones positivas importantes, como la del hierro con el magnesio (0,756) y la del potasio con la proteína (0,737).



Entrenamiento de los modelos

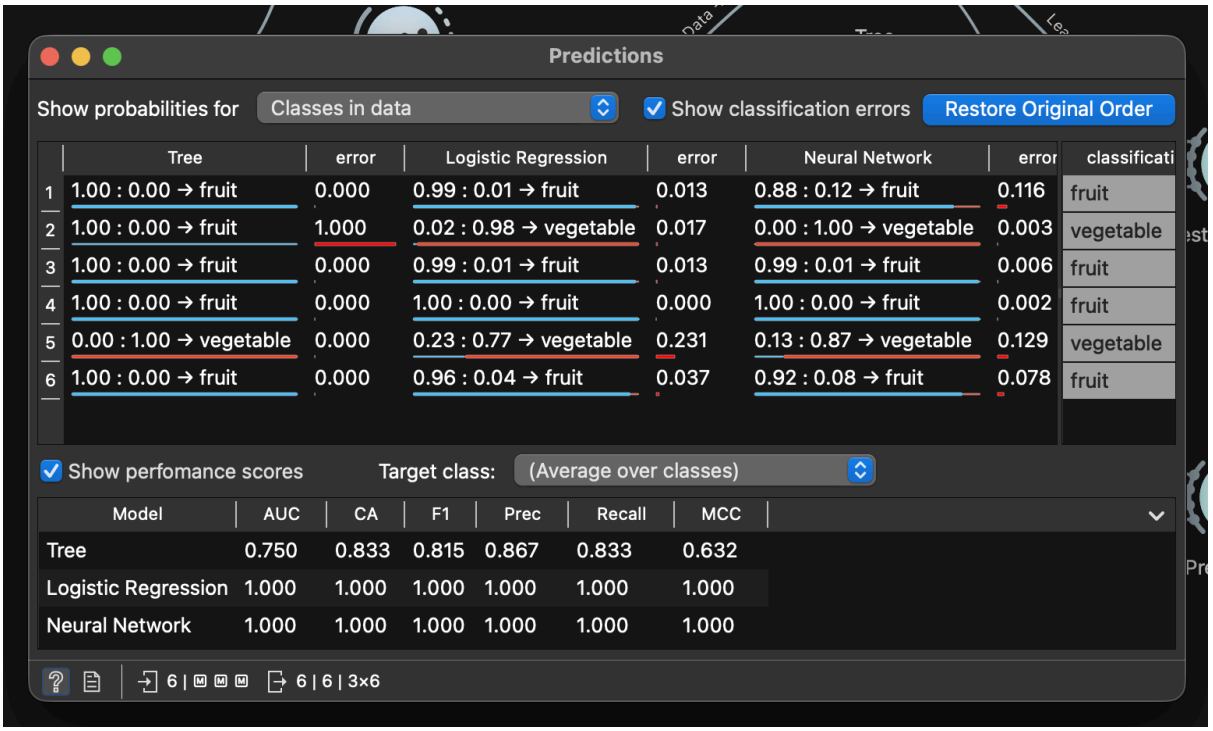
A la hora de intentar clasificar los alimentos, decidimos entrenar tres modelos diferentes: *Tree*, *Logistic Regression* y *Neural Network*. Al evaluarlos en *Test and Score*, vimos que la regresión logística y la red neuronal lograron un 72,2% de aciertos, mientras que el árbol de decisión se quedó un poco atrás con un 69,4%, aunque compensó destacándose con el valor de AUC más alto (0,722).

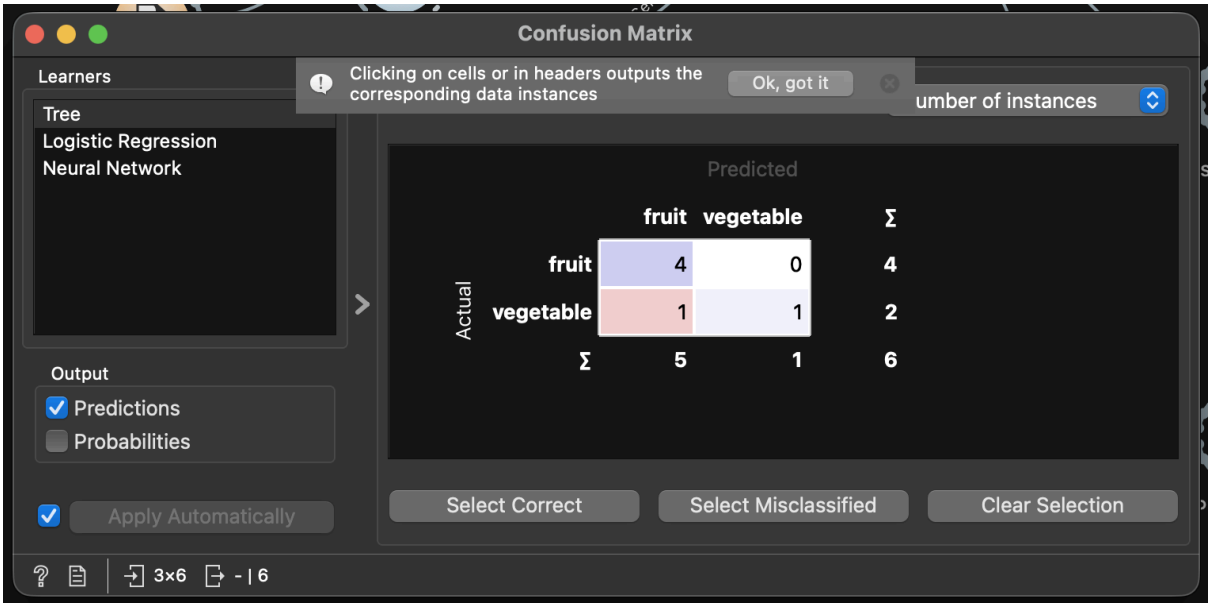




Testeo y matriz de confusión

Pasando a la etapa de testeo, usamos *Predictions* para poner a prueba los modelos con seis alimentos y analizamos los resultados mediante una matriz de confusión y curvas ROC. Los modelos anduvieron bastante bien, acertando en cinco de los seis casos (un 83,33% de exactitud), ya que clasificaron correctamente las cuatro frutas y un vegetal, equivocándose únicamente al etiquetar el otro vegetal como si fuera fruta.





Análisis ROC y conclusiones

Al mirar las curvas ROC, donde acercarse a la esquina superior izquierda marca una mejor discriminación, notamos que *Logistic Regression* y *Neural Network* tuvieron una separación perfecta y superpuesta, mientras que el desempeño de *Tree* fue inferior. Si

bien a simple vista los modelos rindieron mejor en esta prueba que en *Test and Score*, hay que tomarlo con pinzas: como el archivo tiene solo seis registros y tres son idénticos a los del entrenamiento, no podemos asegurar que vayan a mantener este mismo nivel de éxito con alimentos totalmente nuevos.

