Trabajo Práctico de Big Data Data Miners

Clasificación de Clientes mediante Machine Learning en Orange

Materia: Big Data
Tema: Clasificación de clientes bancarios mediante Regresión Logística
Herramienta utilizada: Orange Data Mining

---

1. Introducción

El objetivo de este trabajo práctico es analizar información de clientes bancarios y utilizar técnicas de Machine Learning para predecir si un cliente contratará o no un depósito a plazo fijo.

Para realizar el análisis se utilizó el programa Orange Data Mining y el conjunto de datos Bank Marketing, que contiene información sobre clientes y campañas de marketing realizadas por una entidad bancaria.

Se compararon tres modelos de clasificación: Logistic Regression (Regresión Logística), Random Forest y Naive Bayes.

El propósito fue evaluar cuál de estos modelos ofrece mejores resultados y comprender cómo se pueden utilizar estas predicciones para mejorar las decisiones comerciales del banco.

2. Análisis exploratorio de los datos (EDA)

Antes de entrenar los modelos se realizó un análisis exploratorio para conocer las características de los clientes y observar cómo se distribuyen las principales variables.

El conjunto de datos utilizado contiene **4.119 registros de clientes**.

2.1. Distribución de la variable objetivo (y)

La variable objetivo es y, que indica si un cliente contrató un depósito bancario.

Tiene dos resultados posibles:

- **No:** el cliente no contrató el depósito.
- **Yes:** el cliente sí contrató el depósito.

Al analizar su distribución se observó que aproximadamente el 89 % de los clientes no contrató el producto, mientras que alrededor del 11 % sí lo hizo.

Esto demuestra que los datos están desbalanceados, ya que existe una cantidad considerablemente mayor de respuestas negativas que positivas.

Esta diferencia es importante porque un modelo podría obtener una exactitud elevada simplemente por predecir correctamente a la mayoría de los clientes que no contratarán el depósito, sin identificar adecuadamente a los potenciales compradores.

2.2. Análisis de la variable edad (age)

La variable `age` representa la edad de los clientes.

A partir del gráfico se observó que la mayor concentración de clientes se encuentra en los rangos de edades adultas, especialmente entre aproximadamente 25 y 45 años.

También se observa una menor cantidad de clientes en los grupos de edad más avanzada.

La edad puede ser una variable útil para el análisis, ya que permite estudiar diferentes segmentos de clientes y sus posibles comportamientos frente a las campañas bancarias.

Sin embargo, para afirmar que una edad determinada aumenta la probabilidad de contratación sería necesario realizar un análisis adicional de las proporciones de respuesta positiva en cada grupo.

2.3. Análisis de la variable poutcome

La variable `poutcome` representa el resultado de las campañas de marketing anteriores.

Se identificaron tres categorías:

- **Failure:** la campaña anterior no tuvo éxito.
- **Nonexistent:** no existe un resultado registrado de una campaña anterior.
- **Success:** la campaña anterior fue exitosa.

El gráfico muestra que la mayoría de los clientes pertenece a la categoría `nonexistent` y que dentro de este grupo predominan las respuestas negativas.

En cambio, entre los clientes que habían tenido una campaña anterior exitosa, se observa una mayor proporción de respuestas positivas.

Esto permite concluir que el resultado de las campañas anteriores está relacionado con la contratación del depósito bancario y puede ser una variable relevante para los modelos predictivos.

3. Preparación y división de los datos

Antes de aplicar los modelos se utilizaron herramientas de Orange para seleccionar las variables y preparar la información.

Se emplearon los widgets `Select Columns`, `Impute` y `Continuize` para organizar las variables, tratar los valores faltantes y transformar los datos categóricos para su utilización en los modelos.

Posteriormente, mediante `Data Sampler`, se dividió el conjunto de datos en dos partes:

- **80 % para entrenamiento:** 3.296 clientes.
- **20 % para prueba:** 823 clientes.

Los datos de entrenamiento se utilizaron para construir los modelos y los datos de prueba para evaluar su capacidad predictiva.

En `Test and Score` se seleccionó la opción `Test on test data`, lo que permitió comparar los tres modelos utilizando los mismos datos de evaluación.

4. Comparación de los modelos de clasificación

Se evaluaron tres algoritmos: Random Forest, Logistic Regression y Naive Bayes.

Los resultados obtenidos en Orange fueron los siguientes:

Modelo	AUC	Accuracy (CA)	F1-score	Precision	Recall
Random Forest	0,919	0,916	0,906	0,905	0,916
Logistic Regression	0,942	0,913	0,903	0,900	0,913
Naive Bayes	0,838	0,836	0,857	0,893	0,836

Las métricas F1, Precision y Recall de esta tabla corresponden al promedio sobre las clases mostrado por Orange.

4.1. ¿Qué modelo obtuvo el mejor AUC?

El modelo con el mejor AUC fue **Logistic Regression**, con un valor de 0,942.

El AUC mide la capacidad del modelo para distinguir entre las dos clases: clientes que contratarán el depósito y clientes que no lo contratarán.

Cuanto más cercano a 1 sea este valor, mejor será la capacidad de discriminación del modelo.

Por lo tanto, Logistic Regression obtuvo el mejor resultado en esta métrica, seguido por Random Forest con 0,919 y Naive Bayes con 0,838.

4.2. ¿Qué modelo obtuvo el mejor F1-score?

El modelo con el mejor F1-score promedio fue **Random Forest**, con un valor de 0,906.

Logistic Regression obtuvo 0,903, mientras que Naive Bayes alcanzó 0,857.

El F1-score combina la precisión y la sensibilidad del modelo en una única medida.

Aunque Random Forest obtuvo el mejor F1-score, la diferencia respecto de Logistic Regression fue muy pequeña: solamente 0,003.

Esto indica que ambos modelos lograron resultados competitivos, aunque se destacaron en métricas diferentes.

4.3. ¿Cuál fue el modelo con mejor rendimiento?

No existe un único ganador para todas las métricas.

Logistic Regression obtuvo el mejor AUC (0,942), mientras que Random Forest alcanzó los mejores valores de F1-score (0,906) y exactitud (91,6 %).

Si el objetivo es distinguir y ordenar a los clientes según su probabilidad de contratar, Logistic Regression resulta especialmente conveniente por su mayor AUC.

Por otra parte, si se priorizan las métricas promedio de clasificación, Random Forest mostró una ligera ventaja.

Naive Bayes presentó resultados inferiores a los otros dos modelos.

5. Análisis de la matriz de confusión

Se analizó la matriz de confusión correspondiente a Logistic Regression, utilizando los 823 clientes del conjunto de prueba.

Se obtuvieron los siguientes resultados:

Resultado	Cantidad
Verdaderos positivos (TP)	32
Verdaderos negativos (TN)	719
Falsos positivos (FP)	19
Falsos negativos (FN)	53
Total	**823**

Interpretación de los resultados

Verdaderos positivos (TP = 32): son los clientes que efectivamente contrataron el depósito y que el modelo clasificó correctamente como positivos.

Verdaderos negativos (TN = 719): son los clientes que no contrataron el depósito y que fueron correctamente identificados como negativos.

Falsos positivos (FP = 19): son los clientes que el modelo predijo que contratarían el depósito, pero finalmente no lo hicieron.

Falsos negativos (FN = 53): son los clientes que sí contrataron el depósito, pero que el modelo clasificó incorrectamente como negativos.

¿Qué nos indica la matriz de confusión?

La Regresión Logística clasificó correctamente a 751 de los 823 clientes, obteniendo una exactitud aproximada del 91,3 %.

Sin embargo, de los 85 clientes que realmente contrataron el depósito, el modelo identificó correctamente solamente a 32.

Esto representa una sensibilidad aproximada del 37,6 % para la clase positiva.

Por lo tanto, aunque el modelo tiene una exactitud general elevada, presenta dificultades para detectar a todos los clientes que realmente contratarían el producto.

Desde el punto de vista comercial, los falsos negativos son importantes porque representan oportunidades de contratación que podrían pasar desapercibidas.

Esto demuestra que no es suficiente analizar solamente la exactitud: también es necesario considerar la sensibilidad y los errores de clasificación, especialmente cuando las clases están desbalanceadas.

6. Análisis de las curvas ROC

La curva ROC permite evaluar la capacidad de los modelos para distinguir entre clientes que contratarán y clientes que no contratarán el depósito.

El gráfico representa la relación entre:

- **TPR (True Positive Rate):** proporción de positivos identificados correctamente.
- **FPR (False Positive Rate):** proporción de negativos clasificados incorrectamente como positivos.

Un modelo presenta una mejor capacidad de discriminación cuando su curva se acerca a la esquina superior izquierda del gráfico.

Comparación de las curvas

En el gráfico se observa que Logistic Regression presenta una curva generalmente superior a las de los otros modelos y alcanza el mayor AUC, con un valor de 0,942.

Random Forest obtuvo un AUC de 0,919 y mostró un desempeño cercano al de Logistic Regression.

Naive Bayes presentó una curva inferior y un AUC de 0,838, por lo que su capacidad de discriminación fue menor.

¿Qué modelo ofrece el mejor equilibrio entre TPR y FPR?

Según el análisis de las curvas ROC y sus correspondientes valores de AUC, **Logistic Regression ofrece el mejor rendimiento global para distinguir entre ambas clases**.

Esto significa que, al considerar distintos umbrales de clasificación, presenta una mejor relación general entre la detección de verdaderos positivos y la generación de falsos positivos.

No obstante, la elección del umbral es importante: si el banco quisiera identificar una mayor cantidad de posibles compradores, podría ajustar el umbral de decisión, aceptando un posible aumento de falsos positivos.

7. Conclusión final

A partir del trabajo realizado en Orange Data Mining se pudo comprobar la utilidad de los modelos de Machine Learning para analizar información de clientes bancarios y predecir su comportamiento frente a campañas comerciales.

Se trabajó con un conjunto de 4.119 clientes, dividiendo los datos en 80 % para entrenamiento y 20 % para prueba.

Los tres modelos evaluados mostraron diferencias en su desempeño.

Logistic Regression obtuvo el mejor AUC (0,942), destacándose por su capacidad para distinguir entre clientes que contratarán y clientes que no contratarán el depósito.

Random Forest presentó el mejor F1-score promedio (0,906) y la mayor exactitud (91,6 %), aunque con diferencias pequeñas respecto de Logistic Regression.

Por su parte, Naive Bayes obtuvo el rendimiento más bajo de los tres modelos.

La matriz de confusión permitió identificar una limitación importante: a pesar de su elevada exactitud, Logistic Regression no detectó a todos los clientes que realmente contratarían el depósito.

Esto ocurre en un contexto donde las respuestas negativas representan la gran mayoría de los registros, por lo que resulta importante considerar el desbalance entre las clases.

En conclusión, **Logistic Regression es una alternativa recomendable cuando se prioriza la capacidad de discriminación medida mediante AUC**, mientras que Random Forest también representa una opción competitiva por su rendimiento general.

Este trabajo permitió comprender que los modelos predictivos pueden ayudar a los bancos a identificar potenciales clientes, orientar mejor sus campañas de marketing y tomar decisiones basadas en datos.

También demostró que, para seleccionar un modelo, no alcanza con observar una sola métrica, sino que es necesario evaluar sus resultados, sus errores y el objetivo concreto de su utilización.